剥离作者的阴影: Bamman 文学角色计算模型

Digital Inhumanities 数字不人文研究中心

【摘要】在大规模数字人文研究中，如何将“作者的个人文风”与“角色的真实人设”彻底剥离？本文将通过一场假想的“编辑部对齐实验”，带你像剥洋葱一样拆解 David Bamman 的贝叶斯混合效应模型。我们将把复杂的算法（Dirichlet, SAGE, Gibbs, Laplace）化作破案的工具，娓娓道来这场名为“语义脱水”的数学推演。

【关键词】 数字人文；SAGE 模型；Dirichlet 分布；稀疏性

1. 陷入死胡同的“直觉统计”

在文学人物聚类的早期探索中，学者们抱着一种朴素的直觉观点：只要把一个角色周围经常出现的词汇全抓出来，统计一下频率，就能勾勒出这个角色的“人设”了。

然而，当这种方法被扔进几万本跨越数百年的小说堆里时，遭遇了惨烈的滑铁卢：

- 偏差被无限放大：不同作者描写同一个类型（比如“反派”）的用词天差地别。
- 高维空间里的迷路：当这些带有强烈作者偏好的词汇频率被转换成高维语义向量后，K-means 等聚类算法会直接被带偏。
- 一团乱麻的轮廓系数：聚出来的结果，簇与簇之间像浆糊一样分不开，聚类中心也是一堆毫无性格的常用词。最终，还是得靠语言学家回去翻原著，“凭直觉”去强行解释。

问题出在哪？出在那个在打字机前敲键盘的“幽灵”——作者。Bamman 敏锐地意识到：作者的写作风格就像一个强大的滤镜，它是一个隐藏的概率分布，一直在默默干扰我们对角色用词的观察。

2. 当奥斯汀与狄更斯来到 数字不人文研究中心

为了看清这个“滤镜”有多可怕，我们不妨设定一个极其微观的案发现场。

我们要让两位文风迥异的带文豪——简·奥斯汀与查尔斯·狄更斯，分别去描写我们公众号的两位固定人设：

- 人设 **A** (羊咩咩主编)：核心标签是“治愈、学术、亲和”。
- 人设 **B** (鱼摆摆副主编)：核心标签是“极客、思考、硬核”。

如果我们让算法直接去原著里“数词儿”，我们会得到两份由于作者滤镜不同，而产生严重“语义错位”的口供：

表 **1**：奥斯汀笔下的描述 **(Raw)**

角色	依存关系 **(Role)**	观测词汇与概率
羊咩咩	动作 (Agent)	安慰 (0.15), 倾听 (0.08), 微笑 (0.11)
	受事 (Patient)	被称赞 (0.12), 被感谢 (0.09)
	拥有 (Possessive)	举止 (0.18), 书信 (0.06), 情感 (0.05)
	描述 (Predicative)	温柔的 (0.14), 聪慧的 (0.10)
鱼摆摆	动作 (Agent)	观察 (0.16), 思考 (0.11), 辩论 (0.08)

	受事 (Patient)	被误解 (0.11), 被反驳 (0.07)
	拥有 (Possessive)	品味 (0.13), 见识 (0.09), 财产 (0.05)
	描述 (Predicative)	骄傲的 (0.15), 理智的 (0.12)

表 **2**：狄更斯笔下的描述 **(Raw)**

角色	依存关系 **(Role)**	观测词汇与概率
羊咩咩	动作 (Agent)	哭泣 (0.14), 祈祷 (0.09), 忙碌 (0.07)
	受事 (Patient)	被遗弃 (0.16), 被拯救 (0.11)
	拥有 (Possessive)	起居室 (0.17), 眼泪 (0.12), 善良 (0.08)
	描述 (Predicative)	可怜的 (0.15), 天真的 (0.10)
鱼摆摆	动作 (Agent)	算计 (0.15), 咆哮 (0.08), 凝视 (0.07)
	受事 (Patient)	被畏惧 (0.12), 被起诉 (0.09)
	拥有 (Possessive)	肮脏的 (0.18), 法律 (0.13), 账本 (0.06)
	描述 (Predicative)	阴郁的 (0.13), 固执的 (0.11)

你看，奥斯汀书里的“羊咩咩”总是有着良好的“举止”，而狄更斯笔下的“羊咩咩”则总是待在“起居室”里。算法的终极目标，就是从这些凌乱的表象中，识别出奥斯汀的“举止”和狄更斯的“起居室”，背后其实共享了同一个属于“羊咩咩（治愈型）”的数学分布。

3. 巨人的肩膀：用加法拟合世界 (Additive)

既然直接找人设找不到，我们不如换个思路。Bamman 提出了一个绝妙的假设：当我们选择了一个角色 c，和她的人物抽象类型 p（比如羊咩咩），再让作者 a（比如奥斯汀）去描写她时，产生的那个词语 w（比如“书信”），其实是由几个独立因素共同叠加造成的。

这就是 SAGE 模型中最核心的 **Additive**（加法） 属性。在对数空间里，我们将这种影响的深度拆解成了三个独立参数向量（η）的连加：

$$P(w \mid m, p, r, \eta) = \frac{\exp\left(\eta^0_{r,w} + \eta^{\text{meta}}_{r,w,m} + \eta^{\text{pers}}_{r,w,p}\right)}{\sum_{v=1}^{V} \exp\left(\eta^0_{r,v} + \eta^{\text{meta}}_{r,v,m} + \eta^{\text{pers}}_{r,v,p}\right)}$$

数学小贴士：条件概率与 Logit

这里的 $P(w \mid ...)$ 计算的是在已知作者 m、人设 p 和依存关系 r 的条件下，观测到词语 w 的条件概率。而在词汇树的二元路径选择中，模型使用了 logit^{-1} 函数，即 $\sigma(x) = \frac{1}{1+\exp(-x)}$。它将实数域的得分（Logits）映射到 $(0, 1)$ 区间，从而将其解释为概率。

- η^0_w（时代底噪）：十九世纪大家都爱说话（“talk”）。
- $\eta^{\text{meta}}_{w,m}$（作者的偏离）：奥斯汀偏偏非常喜欢写“书信”这个词。
- $\eta^{\text{pers}}_{w,p}$（人设的偏离）：羊咩咩作为治愈学术型人设，本身也常常与“书信”产生正向联系。

让我们代入刚才的案发现场算一笔账：如果时代底噪对“书信”的打分是 -1.5，奥斯汀的作者偏好给它加了 2.8 分，羊咩咩的人设偏好给它加了 1.2 分。那么最终在奥斯汀书里，羊咩咩带出“书信”的总得分就是 $-1.5 + 2.8 + 1.2 = 2.5$。

通过这种对数线性的加法机制，模型在数学空间里实现了变量的解耦，从而得以把 2.8 的“奥斯汀滤镜”精准剥离，留下 1.2 的纯粹人设。

算力危机与拯救：构建“词汇树” (Cluster Tree)

你看上面那个公式的分母，它需要把词库里所有的词（V）的得分都算一遍来求和。当我们的 η 参数维度极大、真实世界的词汇量也极大时，每次都要全局求和会让计算机算力彻底崩溃。

为了优化计算，模型在这里引入了聚类树（**Cluster Tree**）的方法。 具体来说，每个角色都有 4 棵很大的树，对应 4 种依存关系（动作、受事、拥有、描述）。这 4 种关系下产生的所有具体词语，就是这棵树上的叶子。通过这种树状结构，我们可以将原本对十万个词汇的扁平化 Softmax 计算，转化为一连串的二元逻辑回归（Hierarchical Softmax）。

为了计算一个词的概率，模型实际上是在计算从树根走到该词对应叶子节点的路径概率。假设一个词被编码为一串二进制位比特串 $b = b_1 b_2 ... b_n$（例如 `01011`），那么选择该词的概率就是路径上每一次选择左或右的概率之积。每一次选择的概率分布如下：

$$P(b \mid m, p, r, \eta) = \prod_{j=0}^{n-1} \begin{cases} \mathrm{logit}^{-1}\left(\eta^{\mathrm{meta}}_{r,b_{1:j}}[m] + \eta^{\mathrm{pers}}_{r,b_{1:j}}[p] + \eta^{0}_{r,b_{1:j}}\right) & \text{if } b_{j+1} = 1 \\ 1 - \mathrm{logit}^{-1}\left(\eta^{\mathrm{meta}}_{r,b_{1:j}}[m] + \eta^{\mathrm{pers}}_{r,b_{1:j}}[p] + \eta^{0}_{r,b_{1:j}}\right) & \text{otherwise} \end{cases}$$

公式下标解读：

- b：代表词汇在聚类树中的二进制比特串编码（Bitstring representation）。例如 `01011` 对应“书信”。
- $b_{1:j}$：代表从树根开始的前 j 次路径选择（即决策节点前缀）。每一次路径分叉，都是在做一次微型的 SAGE 加法效应计算。
- r：代表依存关系（如 Possessive）。
- m 和 p：依旧代表作者和人设。

于是，模型真正要建立的，是一张极其复杂的地图查询表：当我知道我在哪棵树上（哪种依存关系 r）、在哪个作家的笔下（作者 m）、以及面对什么人物类型（人设 p）时，模型就会告诉我：在这个路口节点 $b_{1:j}$，我是该选择去树杈的左边（对应概率 $1 - \mathrm{logit}^{-1}$），还是去树杈的右边（对应概率 logit^{-1}）？

这样，极其昂贵的“全局词汇概率求和”，就被优化成了高效的“顺藤摸瓜”式查找，大大减少了参数量，极大地加速了模型的推断过程！

4. 导演入场：不能让外星人乱入 (Dirichlet)

加法模型看起来很棒，但如果我们把视野从编辑部拉大到整个语料库——所有的书，所有的词，所有的角色。如果不加任何限制地去用加法拟合，模型很容易“发疯”。

比如，它可能会为了凑概率，硬生生在列夫·托尔斯泰的《战争与和平》里，拟合出几个属于阿西莫夫宇宙的科幻外星人（极客型人设）。这显然是不符合文学常理的。也就是：我们不希望某一本书里的 **Persona**（人设）处于一种没有规律的交叉混杂状态。

为了防止这种失控，模型在生成过程的顶层，请来了一位名叫 **Dirichlet** 分布 的宏观导演。

数学小贴士：Dirichlet 分布

在生成模型中，每部小说 d 都会从一个先验 α 中抽取一个分布 $\theta_d \sim \mathrm{Dir}(\alpha)$。这决定了这本书里的角色配比。Dirichlet 会输出一串概率密度，α 越小，分布越集中。

- 设置 $\alpha = 0.3$：这本书 80% 都是“羊咩咩型（治愈）”，只有各 10% 是极客或反派。（很符合奥斯汀小说的基调）
- 设置 $\alpha = 0.8$：角色分布更均匀， 30% 治愈，30% 极客，40% 反派。

有了这位导演，即使奥斯汀笔下的“羊咩咩”和“鱼摆摆”偶尔用了相似的词，模型在分配人设时，也会被“奥斯汀的书里治愈型角色应该更多”这个先验约束稳稳拉住。

5. 左右互搏：逼近真相的推断 (Stochastic EM)

现在，框架搭好了，约束有了。但真正的难题来了：在案发现场，我们只知道奥斯汀用了“书信”，狄更斯用了“账本”（这是观测到的真实词频）。我们既不知道角色到底属于什么类型 p（这还是个离散变量），也不知道具体的时代底噪、作者偏好和人设偏好（也就是那堆 η 系数）。

这该怎么学？模型陷入了“鸡生蛋，蛋生鸡”的困境：如果不确定羊咩咩的人设，怎么算奥斯汀的作者偏离？如果不知道奥斯汀的作者偏离，又怎么判断她写的角色到底是不是羊咩咩？

为了打破这个死局，Bamman 采用了一种名为 **Stochastic EM**（随机期望最大化） 的策略，它包含两个不断交替的“左右互搏”步骤：折叠吉布斯抽样（**E-step**）和参数最大化（**M-step**）。

步骤一：E-step（吉布斯抽样——给角色贴标签）

在这个阶段，我们假设 $\boldsymbol{\eta}$ 参数是固定的（哪怕一开始是瞎猜的），任务是为每个角色重新分配一个人设（比如判断她是不是“羊咩咩”型，记为人设 z）。 吉布斯抽样会计算这样一个条件概率：

$$P(p_c = z \mid \ldots) \propto \underbrace{\left(N_{d,-c}^{(z)} + \alpha_z\right)}_{\text{Dirichlet 先验平滑}} \times \underbrace{\prod_{j:r_j=r} P(w_j \mid m, z, r, \eta)}_{\text{当前选词的似然概率}}$$

像侦探一样思考公式：

1. 看大环境（先验）：这本书里，除了当前角色外，被归类为“治愈型（羊咩咩）”的角色多不多？如果这本来就是一本奥斯汀的治愈小说，Dirichlet 平滑项会给出很高的基础分。
2. 看具体口供（似然）：既然我们已经假设了奥斯汀的 η^{meta}（比如知道她爱用“举止”），我们把该角色周围的“举止”、“安慰”这些词代入第 3 节的 SAGE 加法公式。如果在减去奥斯汀的偏好后，剩下的得分完美符合“羊咩咩”的人设 η^{pers}，这部分的似然概率就会暴涨。

结合这两点，模型像掷一枚修改了重心位置的骰子一样，为这个角色重新抽取了一个离散的人设标签 p。因为重心变化逐渐稳定，抽样的结果也会越来越稳定。

步骤二：M-step（参数最大化——调整滤镜系数）

所有角色的标签都贴好后，模型反过来：假设角色的人设 $\boldsymbol{p}$ 全是正确的，现在我们要去调整所有的 η 系数，让目前观测到的“书信”和“账本”的出现概率（总似然）达到最大。

像对质口供一样调整：如果模型发现在被贴上“极客型（鱼摆摆）”标签的角色身上，狄更斯大量使用了“肮脏的”和“账本”；而奥斯汀描写同样的“鱼摆摆”时用了“辩论”和“理智”。在最大化对数似然的过程中，算法为了“最合理地解释这种词汇差异”，会被迫调整权重：把“肮脏的”高分分配给狄更斯的 η^{meta}（作者滤镜），而把“理智的”、“思考”的高分分配给极客型的 η^{pers}（核心人设）。

循环往复：模型就这样在 E-step 重新贴标签，在 M-step 重新调滤镜。几千次迭代后，生成的概率越来越逼近真实的统计频率，最终收敛到一个让整套逻辑最自洽的“真相”。

数学小贴士：M-step 的优化目标

在 M-step 中，模型的目标是找到一组最优参数 $h@\{\eta\}$，使得观测数据的对数似然最大化，同时满足稀疏性约束。其优化函数可表示为：

$$h@\{\eta\} = \arg\max_{\eta} \sum_{j} \log P(w_j \mid m, p, r, \eta) - \lambda \|\eta\|_1$$

这里 $\lambda \|\eta\|_1$ 是 L_1 正则项（由拉普拉斯先验引入）。优化过程采用 **OWL-QN** 算法。

名词解释：拟牛顿法 **(Quasi-Newton)**
这是一种寻找函数极值的高级算法。由于直接计算二阶导数（牛顿法）在海量参数下太慢，拟牛顿法通过“模拟”二阶导数的信息，既保留了快速收敛的优点，又大大节省了计算量。OWL-QN 则是其专门针对 L_1 正则化（不可导点）的变体。

6. 严厉的裁判：逼出纯粹的残差 (Sparse)

在这场几千次的左右互搏中，还有一个致命隐患：如果模型为了偷懒，把一丁点细微的频率变化，都算作是“奥斯汀的偏离”或者“羊咩咩的偏离”，慢慢累积起来，人设的词簇就会变得无比臃肿。

我们不希望偏离是每个因素都造成一点影响形成的累积，我们想要的是——某一些特殊因素引起的强烈偏离！

所以在优化 η 参数（M-step）时，模型引入了一个极其严厉的裁判：拉普拉斯先验（对应 $\boldsymbol{L_1}$ 正则化）：

$$\eta^{\text{meta}}, \eta^{\text{pers}} \sim \text{Laplace}(0, \lambda)$$

这个裁判强迫绝大多数没有明显证据的“偏离系数”归零。只有那些真正定义了 Persona 的词，才能获得非零的 η^{pers}。这种强迫，在 SAGE 模型中被称为 **Sparse**（稀疏性约束）。它确保了定义“羊咩咩”的词簇是有限而精确的。

数学小贴士：拉普拉斯先验与 L1 稀疏性

L1 范数 是指向量中各个元素绝对值之和：$\|\eta\|_1 = \sum |\eta_i|$。

拉普拉斯分布 的概率密度函数为 $f(x) = \frac{1}{2b} \exp\left(-\frac{|x-\mu|}{b}\right)$。在 SAGE 模型中，我们设定 $mu = 0$。

先验概率 **(Prior Probability)** 是指我们在观测到具体文本数据之前，对参数分布的一种“成见”或假设。拉普拉斯先验就是假设绝大多数参数都应该是 0。

拉普拉斯分布 **(L1)**

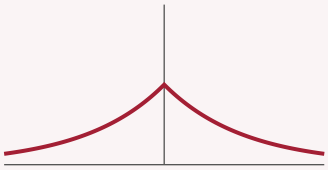

- 输入：权重系数 η
- 输出：该系数的先验概率
- 特性：0 点处有极尖的峰。
- 后果：产生向心力，把权重归零。

与之相对，高斯分布在 0 点处是平滑的，只会让参数变小而不会使其归零。

7. 终章：我们如何得到角色的“身份证”？

经过数千轮的“左右互搏”，模型最终会为每个角色 c 计算出一个后验概率分布 $P(p_c \mid \ldots)$。

什么是后验概率 **(Posterior)**？
简单来说，这是我们在“看完书”之后得到的结论。它的计算遵循贝叶斯法则的核心：后验 $\propto$ 先验 $\times$ 似然 。对于一个角色，她属于某种人设 z 的概率计算如下：

$$P(p_c = z \mid \ldots) \propto \underbrace{\left(N_{d,-c}^{(z)} + \alpha_z\right)}_{\text{先验：这本书里其他人设的分布}} \times \underbrace{\prod_j P(w_j \mid m, z, r, \eta)}_{\text{似然：该角色用词与该人设的匹配度}}$$

这个公式就是角色的“身份证采集过程”。模型会扫描角色周围所有的依存关系词汇，减去作者滤镜后，看剩下的“残差”最符合哪个人设的特征。

什么是 **MAP (**最大后验估计**)**？
MAP 的全称是 *Maximum A Posteriori*。在得到概率清单后（如：羊咩咩 85%，鱼摆摆 10%），MAP 引导我们选择那个概率最大的选项作为该角色的标签。在这个例子中，MAP 验证的是：在排除了所有干扰因素后，逻辑上最自洽的角色归类是什么。

数学小贴士：JS 散度 (Jensen-Shannon Divergence)

当我们拿到了两个角色的后验分布 P 和 Q，如何量化她们的相似度？

JS 散度 是 KL 散度的一种对称化变体，公式为：

$$\mathrm{JS}(P \parallel Q) = \frac{1}{2}\,\mathrm{KL}(P \parallel M) + \frac{1}{2}\,\mathrm{KL}(Q \parallel M)$$

其中 $M = \frac{1}{2}(P + Q)$ 是两个分布的均值。

- 对称性：$\mathrm{JS}(P \parallel Q) = \mathrm{JS}(Q \parallel P)$，这意味着“A 像 B”等同于“B 像 A”。
- 有界性：其值域在 $[0, 1]$ 之间。0 代表分布完全一致，1 代表完全不重叠。
- 文学应用：在 Bamman 的模型中，JS 散度越小，意味着两个角色在剔除作者文风后，其核心“人设残差”越接近，她们在文学功能上越属于同类。

数学小贴士：SAGE vs. LDA

相同点：两者都是生成式概率模型，都利用了 Dirichlet 分布来建模文档层面的隐变量（主题/人设）配比，并常通过 Gibbs 采样进行推断。

不同点：
- 生成机制：LDA 假设词汇直接由多项分布产生；SAGE 则是对数线性模型，认为词汇概率是多个效应（背景、作者、人设）的叠加。
- 核心关注：LDA 倾向于抓取“共性”的主题词簇；SAGE 关注的是“偏离”，即相对于背景分布而言，特定人设特有的词汇。

- 稀疏性：SAGE 通过 L_1 正则化强制产生稀疏解，这让它在处理高维元数据（如成千上万个作者）时比 LDA 更加稳健且具有可解释性。